Curso de Ciência da Computação Pontifícia Universidade Católica de Minas Gerais

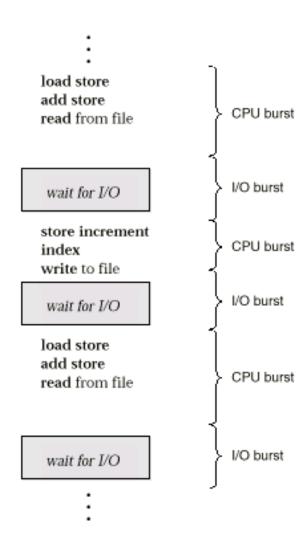
Sistemas Operacionais

Capítulo VI - Escalonamento de CPU

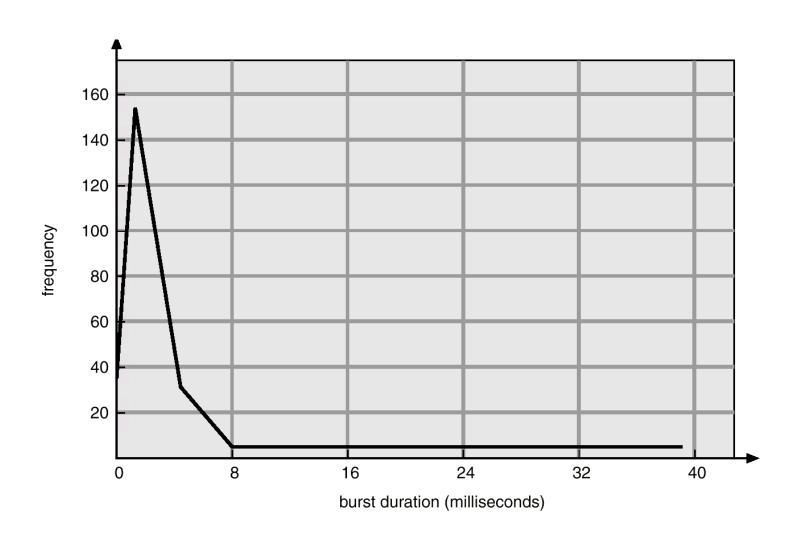
Conceitos Básicos

- ◆ A utilização máxima de CPU é obtida através de multiprogramação. Com um só processador, nunca haverá mais de um processo em execução.
- ◆ Ciclos de surtos de CPU-I/O A execução de um processo consiste na alternância entre um *ciclo* de execução de CPU e um ciclo de espera de I/O.
- ◆ Uma distribuição de surtos de CPU pode ser observada.

Seq**üê**ncia Alternada de Surtos de CPU e I/O



Histograma de Tempo de Surtos de CPU



Escalonador de CPU

- ◆ Seleciona um dentre os processos na memória prontos a serem executados e aloca a CPU para ele.
- ◆ Decisões de escalonamento de CPU ocorrem quando um processo:
 - 1. Passa do estado de execução para espera.
 - 2. Passa do estado de execução para pronto.
 - 3. Passa do estado de espera para pronto.
 - 4. Termina.
- ◆ Quando o escalonamento ocorrem apenas **nos** casos 1 e 4 são chamados *não-preemptivos o processo não é interrompido:*
 - Windows 3. x.
- ◆ Os demais são chamados *preemptivos*:
 - Unix.

Dispatcher

- ◆ 0 módulo de *dispatcher* (executor) dá o controle da CPU ao processo selecionado pelo escalonador de curto prazo. Isto envolve:
 - a mudança do contexto
 - a mudança para o modo usuário
 - pular para a posição adequada no programa do usuário e reiniciar este programa
- ◆ Latência de dispatch tempo necessário ao dispatcher para interromper um processo e iniciar a próxima execução.

Critérios de Escalonamento

- ◆ Características para comparação de algoritmos:
 - Utilização de CPU manter a CPU o mais ocupada possível
 - Throughput # de processos que completam sua execução por unidade de tempo
 - Tempo de retorno quantidade de tempo para executar um processo
 - Tempo de espera quantidade de tempo que um processo gasta na fila de processos prontos
 - Tempo de resposta quantidade de tempo gasto entre a requisição e a produção da primeira resposta

Critérios de Otimização

- ◆ Máxima utilização de CPU
- ◆ Máximo throughput
- ◆ Mínimo tempo de retorno
- ◆ Mínimo tempo de espera
- ◆ Mínimo tempo de resposta

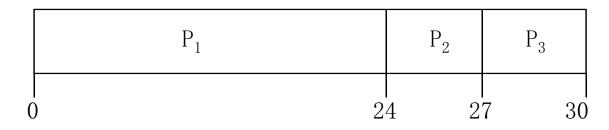
Primeiro a chegar é servido (FCFS)

◆ Exemplo:

<u>Processo</u> <u>Duração de Surto</u>

P_1	24
P_2	3
P_{2}	3

ullet Suponha que os processos chegam na ordem: P_1 , P_2 , P_3 0 diagrama de Gantt para o escalonamento $\dot{\epsilon}$:



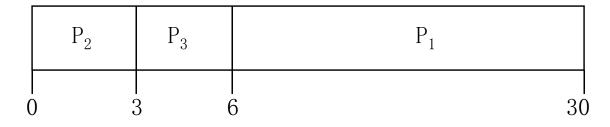
- 0 tempo de espera para $P_1 = 0$; $P_2 = 24$; $P_3 = 27$
- 0 tempo de espera médio: (0 + 24 + 27)/3 = 17

Primeiro a chegar é servido (FCFS)

Suponha que os processos cheguem na ordem

$$P_2$$
, P_3 , P_1 .

♦ 0 diagrama de Gantt para o escalonamento é:



- 0 tempo de espera para $P_1 = 6$; $P_2 = 0$; $P_3 = 3$
- 0 tempo de espera médio : (6 + 0 + 3)/3 = 3
- ◆ Muito melhor que o anterior.
- ◆ *Efeito Comboio:* pequenos processos atrás de longos processos

Escalonamento job mais curto primeiro (SJR)

◆ Associa a cada processos o tamanho do seu próximo surto de CPU. Usa estes valores para escalonar o processo com o menor tempo.

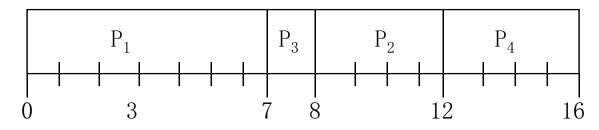
◆ Dois esquemas:

- não-preemptivo uma vez que a CPU é dada ao processo, não pode ser retirada até completar seu surto.
- Preemptivo se um novo processo chegar com um tempo de surto de CPU menor que o tempo restante do processo sendo executado, é feita a troca. Este esquema é conhecido como Menor-tempo-restante-primeiro (SRTF).
- ◆ SJF é ótimo sempre dá o mínimo tempo médio de espera para o conjunto de processos.

Exemplo de SJF Não-preemptivo

<u>Processo</u>	<u>Chegada</u>	<u>Tempo Surto</u>
P_{I}	0.0	7
P_2	2.0	4
P_3	4.0	1
P_4	5.0	4

◆ SJF (não-preemptivo)

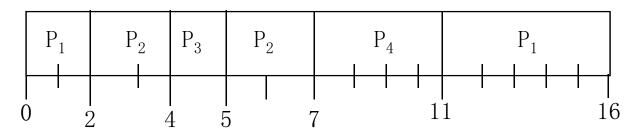


 \bullet Tempo médio de espera = (0 + 6 + 3 + 7)/4 = 4

Exemplo de SJF preemptivo

<u>Processo</u>	<u>Chegada</u>	<u>Tempo de Surto</u>
P_{1}	0.0	7
P_2	2.0	4
P_3	4.0	1
P_4	5.0	4

◆ SJF (preemptivo)



◆ Tempo médio de espera = (9 + 1 + 0 + 2)/4 = 3

Escalonamento por prioridade

- ◆ Um número de prioridade (inteiro) é associado com cada processo
- ◆ A CPU é alocada para o processo com maior prioridade (menor valor ≡ maior prioridade).
 - Preemptivo
 - não-preemptivo
- ◆SJF é um escalonamento por prioridade, onde a prioridade é dada pelo tempo de surto.
- ◆ Problema: Starvation processos com baixa prioridade podem nunca serem executados.
- ◆ Solução ≡ Envelhecimento (Aging) a prioridade aumenta com o tempo.

Round Robin (RR)

- ◆ Cada processo recebe uma pequena unidade de tempo de CPU (*time quantum*), geralmente 10-100 ms. Após este tempo, o processo é retirado e inserido no fim da fila de prontos.
- Se existirem n processos na fila de prontos e o quantum for q, cada processo terá 1/n de tempo de CPU em parcelas de no máximo q unidades de tempo por vez. Nenhum processo esperará mais que (n-1)q unidades de tempo.

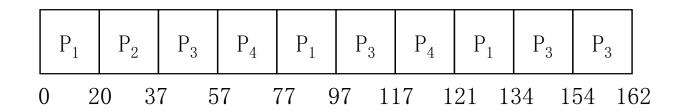
◆ Performance

- q grande \Rightarrow FIF0
- q pequeno $\Rightarrow q$ deve ser grande em relação ao tempo de troca de contexto, ou o overhead será muito alto.

Exemplo: RR com Quantum = 20

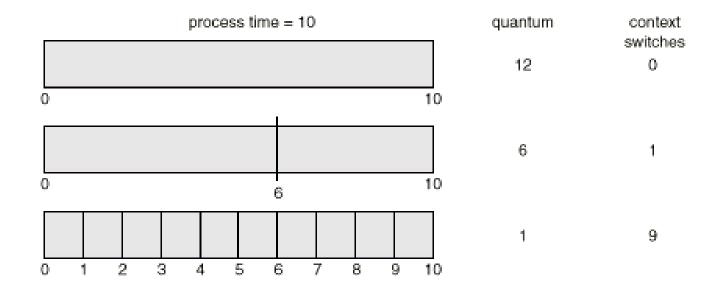
<u>Processo</u>	<u>Tempo de Surto</u>
P_1	53
P_2	17
P_3	68
P_4	24

♦ 0 diagrama de Gantt é:

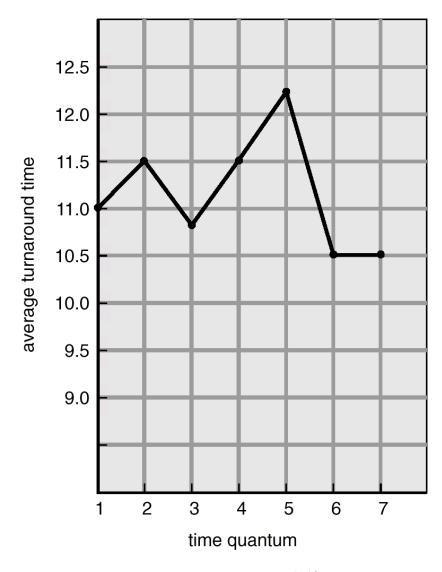


◆ Tipicamente, maior média de retorno que SJF, mas melhor resposta.

Como um Quantum de Tempo menor aumenta as trocas de contexto



Tempo de Retorno varia com o Tempo de Quantum

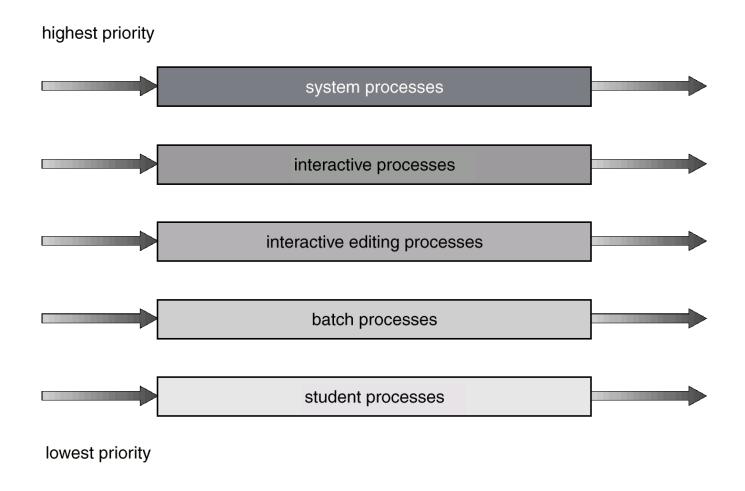


process	time
P ₁	6
P ₂	3
P ₃	1
P ₄	7

Filas Múltiplas

- ◆ A fila de prontos é particionada em filas separadas: primeiro plano (interativo) segundo plano (batch)
- ◆ Cada fila tem seu próprio algoritmo de escalonamento, por exemplo:
 - primeiro plano RR
 - segundo plano FCFS
- ◆ Deve haver escalonamento entre as filas.
 - Escalonamento de prioridade fixa: primeiro plano pode ter prioridade sobre o segundo plano. Possibilidade de starvation.
 - Fatia de tempo cada fila recebe uma certa quantidade de tempo de CPU que pode ser escalonada entre seus processos. Por exemplo, 80% para primeiro plano em RR e 20% para o segundo plano em FCFS

Escalonamento em Filas M**ú**ltiplas



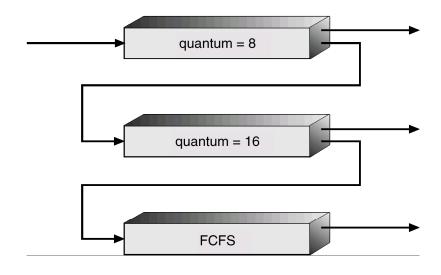
Filas Múltiplas com Realimentação

- ◆ Um processo pode passar de uma fila para outra. 0 envelhecimento pode ser implementado desta maneira.
- ♦ 0 escalonador de Filas Múltiplas com realimentação é definido pelos seguintes parâmetros:
 - número de filas
 - algoritmos de escalonamento para cada fila
 - método usado para determinar a promoção de um processo a uma fila de maior prioridade
 - método usado para determinar quando rebaixar um processo
 - método usado para determinar em qual fila o processo deve entrar quando precisar de serviço.

Exemplo de Filas M**ú**ltiplas com Realimenta**çã**o

◆ Três filas:

- Q_0 quantum 8 ms
- Q_1 quantum 16 ms
- Q_2 FCFS



◆ Escalonador

- Um novo job entra na fila Q_0 servido por FCFS. Quando recebe CPU, o job tem 8 ms. Se não terminar em 8 ms, o job é removido para Q_1 .
- Em Q_1 o job é servido por FCFS e recebe 16 ms adicionais. Se ainda não terminar, é transferido para Q_2 .